



**Departamentul Automatică și Informatică Industrială**

**Facultatea Automatică și Calculatoare  
Universitatea POLITEHNICA din București**



## **Proiect TFAM**

**Analiza fractală a imaginilor de rețină**

**Saioc Marius Andrei**

**2024**

## Cuprins

Introducere .....	2
Stadiul actual .....	3
Metodologie .....	4
Implementare .....	9
Rezultate experimentale și discuții .....	15
Concluzii .....	16
Bibliografie.....	18

## Introducere

Teoria fractalilor, o ramură captivantă a matematicii și a geometriei, explorează modelele complicate întâlnite în natură. Introduși de Benoit Mandelbrot în anii 1970, fractalii sunt forme geometrice complexe care prezintă autosimilaritate la diferite scări. Această proprietate de auto-repetare înseamnă că apropierea de orice parte a unui fractal dezvăluie un model asemănător cu întregul, un fenomen adesea descris ca fiind "infini de complex la orice scară".

Fractalii au apărut ca un instrument puternic pentru înțelegerea și modelarea fenomenelor naturale care sfidează descrierea geometrică tradițională, cum ar fi liniile de coastă, norii, lanțurile muntoase și structurile biologice. Ele oferă o nouă perspectivă asupra aspectelor neregulate și aparent haotice ale lumii naturale, oferind o perspectivă asupra ordinii și structurii care stau la baza acestor sisteme.


Dincolo de aplicațiile lor în natură, fractalii au găsit, de asemenea, o utilizare pe scară largă în diverse domenii, inclusiv în domeniul graficii, al compresiei imaginilor, al prelucrării semnalelor, al finanțelor și al teoriei haosului.

În domeniul imagisticii biomedicale, analiza fractală a participat la interpretarea și diagnosticarea imaginilor medicale, cum ar fi CT (tomografie computerizată), RMN (imagistică prin rezonanță magnetică) și imaginile microscopice. Tehnicile bazate pe fractali au fost utilizate în identificarea modificărilor subtile ale morfologiei țesuturilor asociate cu cancerul, tulburările neurodegenerative și bolile cardiovasculare. În plus, analiza fractală ajută la creșterea eficienței algoritmilor de procesare și segmentare a imaginilor medicale, ceea ce duce la îmbunătățirea rezultatelor pentru pacienți și la detectarea timpurie a bolilor.

Natura fractală a vaselor de sânge din retină îi îndeamnă pe cercetători să investigheze dimensiunea fractală a retinei ca parametru relevant. Această caracteristică, inerentă modelelor complicate de ramificare și structurilor autosimilare ale vaselor retiniene, face din analiza fractală o cale logică de explorare. Utilitatea potențială a dimensiunii fractale a retinei ca instrument de diagnosticare a stârnit un interes substanțial în cadrul comunității științifice. Aceasta oferă un mijloc de cuantificare a complexității vasculaturii retinei, ceea ce promite o mai bună înțelegere și capacități de diagnosticare în diverse boli oculare și sistemice. Decizia concentrare asupra imaginilor de retină pentru acest proiect se bazează pe relevanța practică a analizei dimensiunii fractale în cazul imaginilor de retină.

Fiind cauza principală a orbirii la nivel mondial, bolile retinei fac ca retina să fie extrem de importantă pentru profesioniștii din domeniul oftalmologiei. Retina este un strat neuronal subțire, sensibil la lumină și este alimentată de o rețea microvasculară sofisticată care furnizează nutrienți și elimină deșeurile. Modelul de ramificare al sistemului circulator uman este rezultatul tendinței naturale a rețelei de a căuta configurații care să minimizeze cheltuielile energetice operaționale. Această tendință

este reflectată în Legea lui Murray a efortului minim, care relaționează razele vaselor mamă și fiică [1].



### Stadiul actual

În stadiul actual al imagisticii medicale, dimensiunea fractală joacă un rol în identificarea bolilor oculare. În mod obișnuit, aceasta este utilizată direct în procesele de clasificare sau integrată în algoritmi de procesare a imaginilor pentru segmentare. Cercetătorii valorifică dimensiunea fractală ca măsură cantitativă pentru a evalua complexitatea și neregularitatea structurilor anatomice. Prin detectarea unor modificări subtile ale modelelor fractale, medicii pot diagnostica și monitoriza diverse afecțiuni oculare.

Calculul dimensiunii fractale în imagistica medicală, în special în analiza imaginilor retinei pentru diagnosticarea bolilor, este un efort complex. După cum au subliniat Deepika et al. [2], diferitele metodologii de analiză fractală pot da rezultate diferite. Aceste discrepanțe provin din diferențele metodologice în tehnicile de analiză utilizate, precum și din variațiile introduse în timpul procesului de segmentare vasculară. În consecință, valorile obținute ale dimensiunii fractale pot prezenta inconsecvențe între diferitele abordări analitice. Devine o provocare să se discearnă dacă aceste discrepanțe reflectă cu exactitate diferențele autentice în structura vasculară sau sunt doar artefacte care apar din cauza variațiilor metodologice. Prin urmare, atunci când se utilizează analiza dimensiunii fractale pentru diagnosticarea bolilor, menținerea consecvenței în metodologia aleasă devine primordială pentru a asigura rezultate fiabile și reproductibile.

Dimensiunea fractală se aplică frecvent în studiile privind retinopatia diabetică. Acest lucru se datorează, în primul rând, observațiilor care indică faptul că dimensiunea fractală a distribuției vasculare retiniene la pacienții cu diabet zaharat sever tinde să o depășească pe cea a persoanelor sănătoase [3]. Prin urmare, cercetătorii estimează

adesea dimensiunea fractală a rețelelor vasculare pentru a discerne eventualele anomalii asociate cu retinopatia diabetică.

Retinopatia diabetică poate fi detectată prin mai multe caracteristici, cum ar fi [4]: 1) Microanevrisme (MA), care sunt deformări ale pereților vaselor de sânge și pot fi văzute în formă de balon; 2) Hemoragii (HMA), care au rezultat din scurgerile de sânge din capilarele deteriorate; 3) Exudate, care au rezultat din scurgerile de sânge din vene.


Studiul lui Safitri [3] a concluzionat că diagnosticarea retinopatiei diabetice poate fi realizată în mod eficient prin examinarea imaginii fundului de ochi folosind analiza dimensiunii fractale, în special prin utilizarea metodei box-counting și a clasificării KNN. Studiul a observat că valorile dimensiunii fractale ale imaginilor fundului de ochi cu retinopatie diabetică au fost mai mari în comparație cu cele ale imaginilor normale ale fundului de ochi, cu o creștere corespunzătoare gravității retinopatiei diabetice. În plus, clasificarea retinopatiei diabetice utilizând analiza dimensiunii fractale și prelucrarea imaginilor a demonstrat valori de precizie promițătoare, atingând 89,17% cu clasificatori 3NN sau 4NN, indicând o performanță puternică în clasificarea bolii.

Într-un alt studiu, Alzami et al. au efectuat, de asemenea, cercetări axate pe analiza fractală pentru clasificarea gradului de retinopatie diabetică [5]. Studiul lor a evidențiat potențialul analizei fractale în distingerea între indivizii sănătoși și pacienții cu retinopatie diabetică. Cu toate acestea, ei au constatat limitări în capacitatea sa de a diferenția între cazurile ușoare și severe de retinopatie diabetică. Această constatare subliniază provocările nuanțate inerente în utilizarea exclusivă a analizei fractale pentru clasificarea bolilor de retină.

Mergând mai departe, cu rolul de a experimenta calculul și aplicarea dimensiunilor fractale, acest proiect se va concentra pe analiza a două texturi diferite din imaginile de retină, construind un clasificator care să le distingă pe baza dimensiunilor fractale.

## Metodologie

Imagistica retinei se referă la procesul de captare a imaginilor detaliate ale retinei, care este țesutul sensibil la lumină situat în partea din spate a ochiului. Tehnicile de imagistică a retinei cuprind o serie de modalități, inclusiv fotografia fundului de ochi, tomografia în coerență optică (OCT), angiografia cu fluoresceină și imagistica cu autofluorescență a fundului de ochi. Fotografia fundului de ochi presupune captarea de imagini color de înaltă rezoluție ale retinei cu ajutorul unor camere specializate, permițând vizualizarea unor structuri precum nervul optic, vasele de sânge și macula.



*Figura 1*

Figura 1 prezintă caracteristicile anatomice, cum ar fi discul optic (OD), fovea, vasele de sânge și anumite patologii, cum ar fi exudatele, hemoragiile și microanevrismele dintr-o imagine retiniană tipică. OD este regiunea gălbuie și strălucitoare din care axonul ganglionar iese din ochi pentru a forma nervul optic. Exudatele sunt depozitele lipidice de culoare galbenă strălucitoare care apare cu o culoare similară cu cea a OD. Exudatele apar în principal din cauza scurgerilor din vasele capilare. Hemoragiile sunt pete roșii mai mari și întunecate, iar microanevrismele apar ca niște puncte roșii mici. Centrul retinei se numește fovea. Prezența exudatelor și a microanevrismelor reprezintă principalul semn al retinopatiei diabetice.

În cadrul proiectului se vor folosi secțiuni din imagini de retină cu care se vor alcătui două clase, pentru discul optic și exudate. Pentru aceste imagini se vor calcula următoarele dimensiuni: dimensiune fractală Hausdorff, lacunaritate, contrast, disimilaritate, omogenitate, energie, corelație, entropie, varianță.

Dimensiunea fractală servește ca o măsură cantitativă vitală pentru caracterizarea obiectelor fractale, reflectând neregularitatea acestora. De obicei, aceasta depășește dimensiunea topologică, dar nu atinge dimensiunea euclidiană. Obiectele fractale prezintă structuri fine la scări mici și caracteristici fragmentate, sfidând descrierile geometrice sau topologice convenționale. Autosimilaritatea sau cvasi-autosimilaritatea și o lege de generare simplă și recursivă sunt trăsături tipice. Dimensiunea Hausdorff, printre diferitele dimensiuni fractale, se remarcă prin aplicabilitatea sa universală, bazându-se pe măsuri care pot fi gestionate matematic. Cu toate acestea, calculul său ridică adesea probleme. Felix Hausdorff a introdus o abordare iterativă pentru definirea măsurii obiectelor neregulate, crucială pentru înțelegerea matematicii fractale. Această metodă implică acoperiri succesive ale obiectelor fractale, contorizând numărul de vecinătăți necesare pentru acoperire. Ea este aplicabilă nu numai fractalilor perfect

autosimilari, ci și celor mai puțin regulate. Regresia liniară asupra punctelor de pe un grafic log-log dă dimensiunea fractală.

Formula de calcul a dimensiunii fractale Hausdorff:

$$D_H = \lim_{k \rightarrow \infty} \frac{\log(N_k)}{\log(1/r_k)}$$

unde : -  $N_k$  – numărul de vecinătăți care conțin o parte din obiect;  
-  $r_k$  – dimensiunea laturii grilei de acoperire / diametrului cercurilor de acoperire.

Lacunitatea, introdusă în analiza imaginilor fractale de Mandelbrot în 1977, îmbunătățește descrierea structurilor fractale interne. În mod intuitiv, o lacunaritate ridicată indică prezența unor goluri sau lacune în cadrul unei structuri fractale. În esență, valorile ridicate ale lacunarității sugerează că pixelii sunt grupați, formând o mare varietate de insule sau goluri. Evaluarea lacunarității servește drept instrument valoros în analiza texturii, unde o lacunaritate ridicată semnifică o eterogenitate puternică a texturii, în timp ce valorile scăzute denotă omogenitate. Dincolo de măsura sa intuitivă, lacunaritatea cuantifică caracteristici suplimentare ale formei, cum ar fi invarianța la rotație și eterogenitatea generală.

O lacunaritate mai mare indică o variație mai mare a distribuției pixelilor într-o imagine. Aceasta implică faptul că pixelii sunt grupați într-o gamă largă de dimensiuni de insule, înconjurată de goluri foarte variate, ceea ce indică un model spațial sau o eterogenitate a texturii.

Pentru calcularea dimensiunilor fractale, se va utiliza algoritmul Differential Box Counting (DBC), o extensie a algoritmului clasic box-counting. Propus de Sarker și Chaudhuri [6], acest algoritm demonstrează o clasificare eficientă a texturilor în imaginile în tonuri de gri. Pentru a calcula dimensiunea fractală în imaginile în tonuri de gri, se creează un relief 3D, acoperit cu casete de dimensiuni  $r \times r \times s$ , unde  $r$  este factorul de divizare și  $s$  este înălțimea fiecărei casete, definită ca  $s = r * I_{\max}/M$ ,  $I_{\max}$  reprezentând valoarea maximă a intensității și  $M \times M$  fiind dimensiunea imaginii.

Algoritmul urmează următorii pași:

1. Pentru fiecare dimensiune  $r$  a casetei, se calculează diferența dintre cea mai mare și cea mai mică valoare a tonurilor de gri din interiorul casetei în poziția  $(u,v)$ . Se adaugă 1 pentru a evita problemele cu valorile nule, conform ecuației:  
 $nr(u,v) = p(u,v) - q(u,v) + 1$
2. Se însumează aceste diferențe pentru toate casetele.  
 $Nr = \sum (u,v) (p(u,v) - q(u,v) + 1)$
3. Trasăm punctele cu logaritmul dimensiunii casetei pe o axă și cu logaritmul sumei diferențelor pe cealaltă axă ( $\log 1/r$ ,  $\log Nr$ ).

4. Folosind regresia liniară, se găsește panta dreptei care se potrivește cel mai bine acestor puncte. Această pantă oferă o măsură aproximativă a dimensiunii fractale a imaginii.

Pentru imagini cu mai multe niveluri de gri, lacunaritatea pentru factorul de divizare  $r$  se bazează pe algoritmul box-counting diferențial:

$$L(r) = \frac{\sum_N N^2 \cdot P(N, r)}{\left[ \sum_N N \cdot P(N, r) \right]^2},$$

unde  $P(N, r)$  reprezintă probabilitatea de apariție a valorii  $nr(u, v)$  pe toată imaginea.

Pentru determinarea măsurilor statistice se va folosi Gray Level Co-occurrence Matrix (GLCM) Matricea de co-ocurență în GLCM captează relațiile spațiale prin analiza frecvenței cu care nivelurile de gri apar împreună într-o imagine, concentrându-se pe pixelii vecini.

GLCM ia în considerare anumite distanțe între pixeli (adesea 1 sau 2) și direcții (de exemplu, orizontală, verticală, diagonală) pentru a surprinde aranjamentul spațial al texturilor.

Cei trei parametri utilizați în calculul GLCM sunt [7]:

1. Distanța ( $d$ ): Definește deplasarea dintre doi pixeli.
2. Unghiul ( $\theta$ ): Determină direcția în care sunt luate în considerare perechile de pixeli, de obicei în  $0^\circ$ ,  $45^\circ$ ,  $90^\circ$  și  $135^\circ$ .
3. Numărul de niveluri de gri ( $G$ ): Denotă numărul de niveluri discrete de intensitate din imagine. În GLCM, intensitățile pixelilor sunt reprezentate ca "grays", variind de la 0 (negru) la 255 (alb) pentru imagini pe 8 biți.

După ce se calculează GLCM, se pot extrage diverse măsuri statistice din aceasta pentru a descrie textura și structura imaginii. Printre caracteristicile utilizate în mod obișnuit se numără [8]:

1. Contrast: Evaluează variațiile locale din imagine. Valorile mai mari ale contrastului indică diferențe semnificative între intensitățile pixelilor adiacenți.

$$\text{'contrast': } \sum_{i,j=0}^{levels-1} P_{i,j} (i - j)^2$$

2. Disimilaritate: Calculează diferența medie de intensitate între pixelii vecini. Valorile mai mari ale disimilarității sugerează o eterogenitate mai mare a texturii.

$$\text{'dissimilarity': } \sum_{i,j=0}^{levels-1} P_{i,j} |i - j|$$



3. Omogenitate: Indică proximitatea distribuției elementelor din GLCM față de diagonala sa. Valorile mai mari ale omogenității implică faptul că elementele sunt concentrate de-a lungul diagonalei, indicând o textură mai uniformă.

$$\text{'homogeneity': } \sum_{i,j=0}^{levels-1} \frac{P_{i,j}}{1+(i-j)^2}$$

4. Energie (sau ASM - al doilea moment unghiular): Reflectă ordonarea sau uniformitatea imaginii. Valorile mai mari ale energiei semnifică o textură mai uniformă.

$$\text{'ASM': } \sum_{i,j=0}^{levels-1} P_{i,j}^2$$

$$\text{'energy': } \sqrt{ASM}$$

5. Corelație: Măsoară relația liniară dintre perechile de pixeli. Valorile mai mari ale corelației indică o textură mai previzibilă.

$$\sum_{i,j=0}^{levels-1} P_{i,j} \left[ \frac{(i - \mu_i)(j - \mu_j)}{\sqrt{(\sigma_i^2)(\sigma_j^2)}} \right]$$

Entropie: Reflectă caracterul aleatoriu sau dezordonat al texturii. Valorile mai mari ale entropiei indică o mai mare imprevizibilitate în dispunerea intensităților pixelilor.

$$- \sum_{i=0}^{n-1} \sum_{j=0}^{n-1} p(i, j) \log_b p(i, j)$$

unde  $p(i, j)$  reprezintă valorile din GLCM.

Varianță: Măsoară variabilitatea sau răspândirea intensităților pixelilor din imagine. Valorile mai mari ale varianței indică o diversitate mai mare a intensităților pixelilor.

$$\text{Variance} = \sum_{i=0}^{G-1} \sum_{j=0}^{G-1} P(i, j) \cdot (i - \mu)^2$$

unde  $\mu$  este media nivelurilor de gri din GLCM.

Baza de date utilizată în acest proiect este setul de date Color Fundus Image Vessel Segmentation (FIVES) [9], special creat pentru segmentarea precisă a vaselor retiniene. Acest set de date cuprinde 800 de fotografii color de fund de ochi de înaltă rezoluție care

prezintă diverse afecțiuni ale retinei. Fiecare imagine a fost supusă unei adnotări manuale meticuloase la nivel de pixel, un proces standardizat realizat de experți medicali prin crowdsourcing.


## Implementare

Proiectul a fost dezvoltat folosind Python în cadrul mediului de dezvoltare integrat (IDE) PyCharm. Python a oferit o platformă versatilă și eficientă pentru implementarea diferiților algoritmi de procesare a imaginilor și de învățare automată.

Pentru extragerea secțiunilor care conțin discul optic și exudate din fotografiile din setul de date FIVES, a fost adoptată o abordare manuală. Cu ajutorul Adobe Photoshop, fiecare imagine a fost prelucrată meticulos pentru a decupa zonele în pătrate de 500x500 pixeli. În total, au fost obținute 167 de secțiuni cu discul optic și 94 de secțiuni cu exudate. Această extragere manuală a asigurat selecția și izolarea precisă a regiunilor de interes, permițând o analiză și o clasificare precisă a discului optic și a exudatelor.




*Figura 2: Secțiuni disc optic*



*Figure 3: Secțiuni exudate*


Ulterior, patch-urile extrase au fost prelucrate în continuare prin izolarea lor pe canalele RGB pentru o analiză ulterioară.



*Imagine originală – Canal R – Canal G – Canal B*

Pentru fiecare canal, dimensiunea fractală și lacunaritatea au fost determinate utilizând algoritmul Differential Box Counting implementat. În plus, au fost calculați descriptorii statistici, inclusiv contrastul, disimilaritatea, omogenitatea, energia, corelația, entropia și varianța. Această analiză a fost facilitată prin utilizarea bibliotecii Python "skimage.feature", care utilizează funcțiile "graycomatrix" și "graycoprops" pentru a extrage măsurile statistice dorite.

După obținerea acestor valori de date, s-au calculat media și deviația standard a datelor pentru fiecare canal de culoare, pentru fiecare trăsătură. Astfel, s-au analizat datele pentru a putea observa dacă sunt diferite pe cele două clase.



*Figura 4: Dimensiunea fractală comparație canale rgb*




Figura 5: Lacunaritate comparație canale rgb



Figura 6: Constrast comparație canale rgb




Figura 7: Disimilaritate comparație canale rgb




Figura 2: Omogenitate comparație canale rgb




Figura 9: Energie comparație canale rgb




Figura 10: Corelație comparație canale rgb

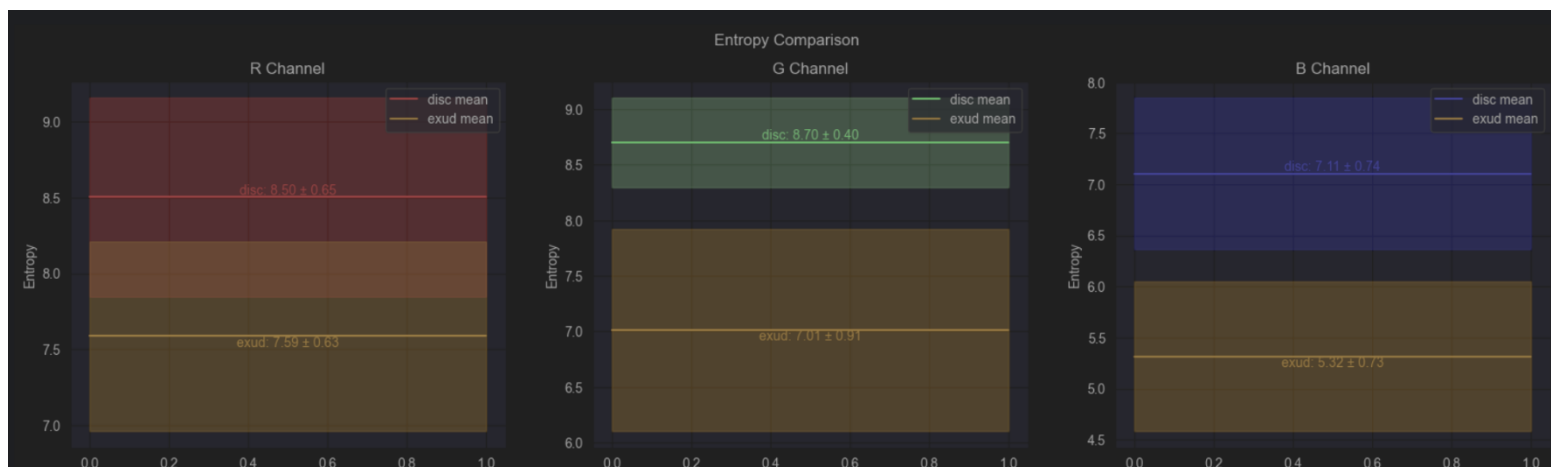


Figura 3: Entropie comparație canale rgb




Figure 12: Varianță comparație canale rgb

După cum se poate observa în graficele de mai sus, pentru dimensiunea fractală, lacunaritate și contrast, valorile sunt relativ apropiate pentru cele două clase, deviația standard suprapunându-se pe toate cele trei canale de culoare. Însă, existând cel puțin un canal de culoare pentru care această suprapunere este mică, se va alege acel canal pentru includerea în clasificator.

În dreptul celorlalte trăsături, se observă cel puțin un canal de culoare pe care datele se diferențiază clar, și se aleg canalele cu diferențierea cea mai mare.

Astfel pentru includerea în clasificator se vor alege următoarele combinații: dimensiune fractală – canal albastru, lacunaritate – canal verde, contrast – canal roșu, disimilaritate – canal roșu, omogenitate – canal albastru, energie – canal verde, corelație – canal albastru, entropie – canal albastru, varianță- canal roșu.

Pentru a înțelege mai bine relevanța fiecărei trăsături în scopul clasificării, distribuția valorilor pentru fiecare trăsătură este reprezentată grafic și poate fi observată în Figura 13. Înainte de afișare, anumite caracteristici, cum ar fi "Fractal Dimension", "Contrast", "Dissimilarity", "Entropy" și "Variance", sunt normalizate, valorile lor originale fiind în afara intervalului  $[0,1]$ .

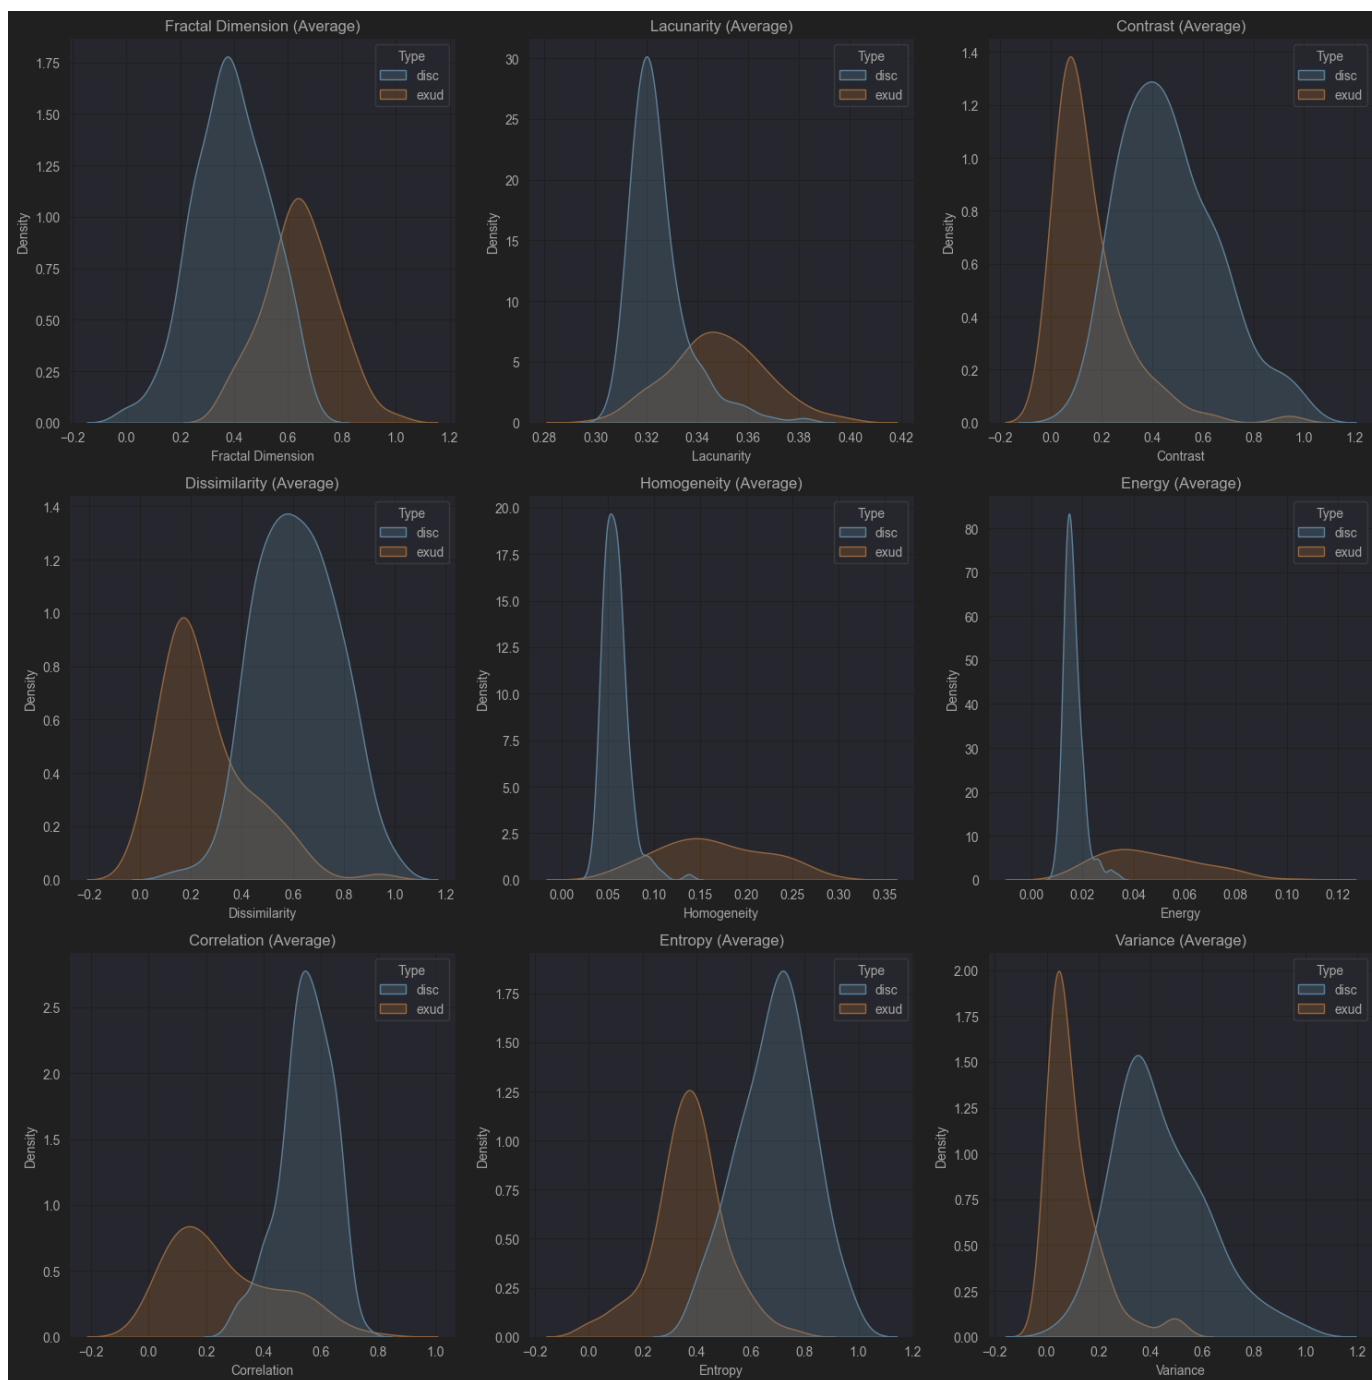


Figura 13: Distribuțiile trasaturilor celor doua clase

După observarea distribuției datelor, a fost evident că toate celelalte nouă caracteristici par relevante pentru sarcina noastră de clasificare. Prin urmare, s-a trecut la separarea datelor în seturi de antrenament și de testare, utilizând un raport de separare de 70/30.

Clasificatorii aleși în acest proiect sunt RandomForestClassifier, KNeighborsClassifier, SVC și GaussianNB. RandomForestClassifier este o metodă de învățare de ansamblu care funcționează prin construirea unei multitudini de arbori de decizie la momentul învățării. KNeighborsClassifier este un algoritm de învățare simplu, dar eficient, bazat pe instanțe, care clasifică noile instanțe pe baza unor măsuri de similaritate, cum ar fi distanța. SVC, sau Support Vector Classifier, este un algoritm de clasificare puternic care găsește hiperplanul optim într-un spațiu cu dimensiuni mari pentru a separa diferite clase. GaussianNB, sau Gaussian Naive Bayes, este un clasificator probabilistic bazat pe teorema lui Bayes, cu ipoteza independenței între caracteristici.

## Rezultate experimentale și discuții

După antrenarea celor 4 modele pot fi observate următoarele rezultate, acuratețea, respectiv matricea de confuzie.

Random Forest: 0.95

27	2
2	48

KNeighbors: 0.95

27	3
1	49

SVC: 0.95

27	2
2	48

GaussianNB: 0.95

28	1
3	47

Se poate observa că toate cele patru modele oferă rezultate bune, cu o precizie identică de 0,95. Random Forest și SVC au dat rezultate identice (două fals pozitive și două fals



negative), KNeighbors a identificat greșit o singură imagine cu disc optic, dar trei imagini cu exudate, pe când GaussianNB tocmai invers, atribuind greșit trei imagini de disc optic și doar una cu exudate.

Pentru că la alegerea primelor trei trăsături s-a observat o suprapunere mică a datelor s-a încercat aplicarea clasificatorilor eliminând pe rând câte o trăsătură, având următoarele concluzii:

- la eliminarea contrastului rezultatele s-au păstrat, fiind identice cu cele văzute anterior. Astfel contrastul este o trăsătură inefficientă, necontribuind la procesul de clasificare
- la eliminarea lacunarității acuratețea scade pe toate cele patru modele, astfel lacunaritatea va fi păstrată
- la eliminarea dimensiunii fractale acuratețea a scăzut la 0,94 pentru Random Forest, KNeighbors și SVC, dar crește la 0,96 pentru GaussianNB cu următoare matrice de confuzie:

GaussianNB: 0.96

28	1
2	48

## Concluzii

În acest proiect, s-a propus o studiere a dimensiunilor fractale aplicate la analiza imaginilor retiniene, cu scopul de a dezvolta un clasificator capabil să distingă între două texturi distincte prezente în imaginile de retină. Valorificând versatilitatea și eficiența limbajului Python în cadrul mediului de dezvoltare integrat (IDE) PyCharm, metodologia a integrat fără probleme diverși algoritmi de procesare a imaginilor și de învățare automată.

Abordarea a început cu extragerea manuală meticuloasă a secțiunilor care conțin discul optic și exudatele din fotografiile din setul de date FIVES, asigurând precizia în izolarea regiunilor de interes pentru analiza ulterioară. Aceste patch-uri au fost apoi supuse unei prelucrări suplimentare prin izolarea lor pe canalele RGB, ceea ce a permis extragerea descriptorilor statistici cheie și dimensiunile fractale cu ajutorul algoritmului diferențial Box Counting.

Calcularea ulterioară a măsurilor statistice și a dimensiunilor fractale pe fiecare canal a facilitat o analiză cuprinzătoare a caracteristicilor texturii în toate imaginile de retină. Prin compararea distribuției datelor s-au ales canalele de culoare mai avantajoase

pentru fiecare trăsătură în parte. Normalizarea anumitor trăsături a fost considerată necesară din cauza faptului că valorile lor originale erau mari, putând altera procesul de clasificare.

În urma observării distribuției datelor, s-a constatat că toate caracteristicile sunt pertinente pentru sarcina de clasificare. În consecință, s-a procedat la formarea și testarea a patru clasificatori distincți: RandomForestClassifier, KNeighborsClassifier, SVC și GaussianNB. Rezultatele experimentale au evidențiat procente promițătoare pentru toți clasificatorii, cu o precizie de 0,95 pentru toți patru.

În concluzie, acest proiect evidențiază utilitatea dimensiunilor fractale în analiza imaginilor de retină, prezentând potențialul de îmbunătățire a preciziei de clasificare prin selectarea meticuloasă a trăsăturilor și optimizarea modelului.

## Bibliografie

- [1] Murray, C.D. The Physiological Principle of Minimum Work: I. The Vascular System and the Cost of Blood Volume. *Proc. Natl. Acad. Sci. USA* 1926, 12, 207–214. [CrossRef] [PubMed]
- [2] Deepika, Jeyalakshmi, V., Latha, P., Raman, R., Srinivasalu, S., R, J. S., Raman, S., & Kandle, K. (2021). Comparison of various fractal analysis methods for retinal images. *Biomedical Signal Processing and Control*, 63, 102245.
- [3] Safitri, D. W., & Juniati, D. (2017). Classification of diabetic retinopathy using fractal dimension analysis of eye fundus image. *AIP Conference Proceedings*.
- [4] M. R. K. Mookiah, U. R. Acharya, C. K. Chua, C. M. Lim, E. Y. K. Ng, and A. Laude, “Computer-aided diagnosis of diabetic retinopathy: A review,” *Comput. Biol. Med.*, vol. 43, no. 12, pp. 2136–2155, 2013.
- [5] Alzami, F., Abdussalam, Megantara, R. A., Fanani, A. Z., & Purwanto, P. (2019). Diabetic Retinopathy Grade Classification based on Fractal Analysis and Random Forest. 2019 *International Seminar on Application for Technology of Information and Communication (iSemantic)*.
- [6] Sarkar, N., & Chaudhuri, B. B. (1994). An efficient differential box-counting approach to compute fractal dimension of image. *IEEE Transactions on Systems, Man, and Cybernetics*, 24(1), 115–120.
- [7] Ajmera, G. (2024, February 16). Feature Extraction of Images using GLCM (Gray Level Cooccurrence Matrix). *Medium*. <https://medium.com/@girishajmera/feature-extraction-of-images-using-gldm-gray-level-cooccurrence-matrix-e4bda8729498>
- [8] Hall-Beyer, M. (2017). *GLCM Texture: A Tutorial V. 3.0* March 2017.
- [9] Jin, K., Huang, X., Zhou, J., Li, Y., Yan, Y., Sun, Y., Zhang, Q., Wang, Y., & Ye, J. (2022). FIVES: A Fundus Image Dataset for Artificial Intelligence based Vessel Segmentation. *Scientific Data*, 9(1).